

# Лекция 1. Концепция Больших Данных



## Основные вопросы

- Определение больших данных
- Параллельные и распределенные вычисления
- Системы обработки и хранения больших данных
- Стек технологий
- Облачные ресурсы


# Определение больших данных

## Системы обработки больших данных

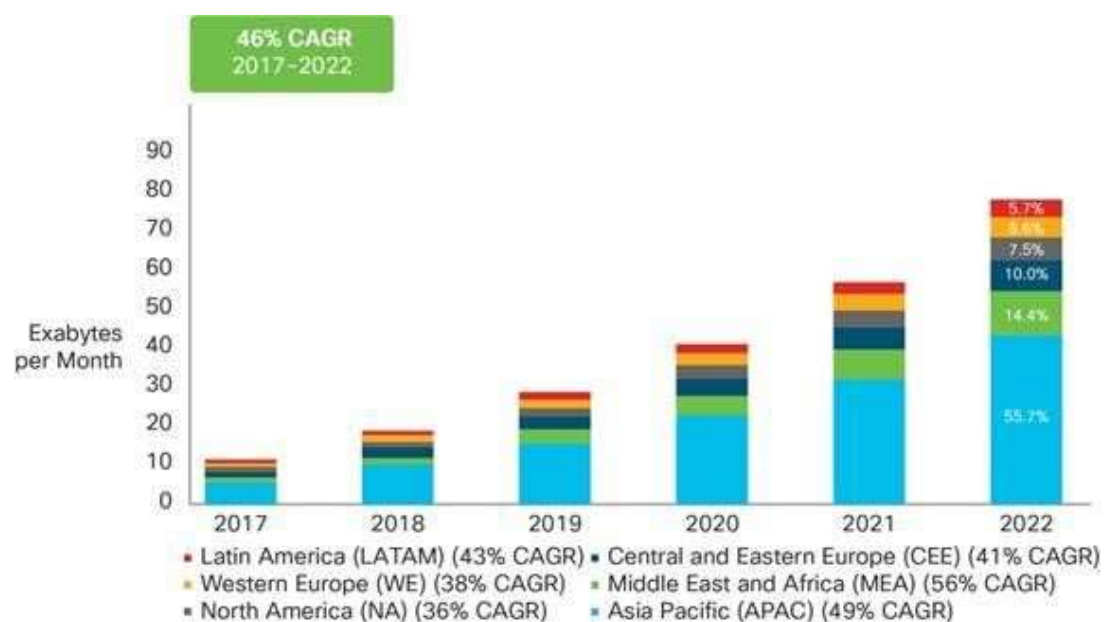

## Статистика

### Пример, Facebook

- 2.23 млрд. активных пользователей в месяц (2018)
- 90,032 постов в день (2018)




domo.com



Cisco Visual Networking Index: Global Mobile Data Traffic Forecast

## Большие Данные – 4V



## Цель обработки Больших Данных

- Чем больше данных у нас есть, тем больше знаний мы можем извлечь, лучшее решение можем принять
- Чем быстрее обрабатываются поступающие данные, тем быстрее можно начать анализ
- Чем более разнообразные источники данных (социальные сети, история просмотров, покупок и пр.), тем лучше можно составить портрет клиента
- Чем более достоверные данные, тем точнее можно составить портрет клиента

# Источники данных

## Публичные данные

Экономические  
Перепись  
Гео-информация  
Погода  
Открытые данные

## Коммерческие данные

Бизнес-информация  
Исследования рынка  
Кредитное бюро

## Социальные сети

Сообщества  
Блоги  
Twitter, Facebook, LinkedIn, Tumblr

## Операционные данные

Сенсоры  
GPS  
Транзакции

## Корпоративные данные

Взаимодействия с клиентами  
Отчеты  
Логи  
Контакты




# Основные задачи систем обработки больших данных

- ETL (Extract, Transform, Load)
- Поиск информации
- Анализ данных
- Машинное обучение

# ETL - Extract Transform Load

## ETL. Общая схема

- Извлечение данных из различных внешних источников (БД, приложения, системы)
- Преобразование и очистка данных в соответствии с целями обработки
- Загрузка результата в хранилище данных



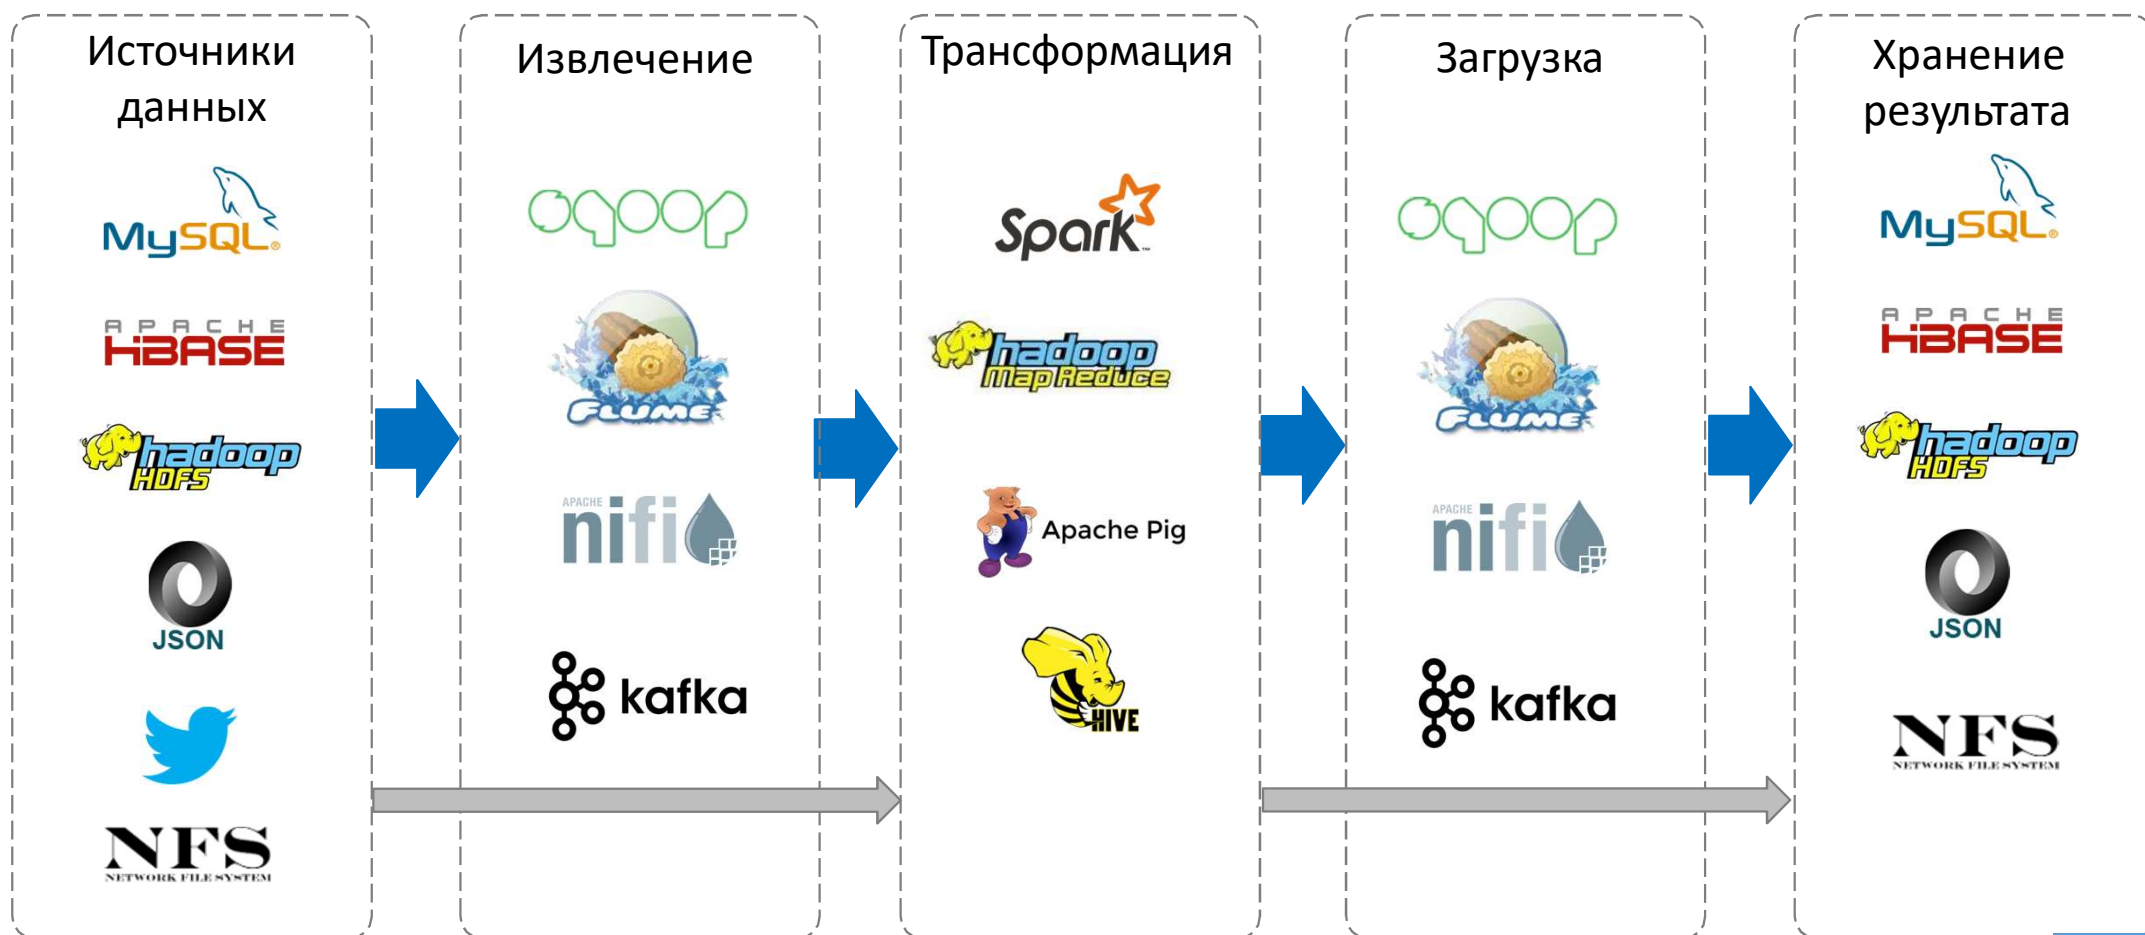
## ETL. Базовые трансформации

- **Очистка (cleaning)**  
обработка null значений, пропущенных данных, аномальных значений и пр.)
- **Преобразование формата (format revision)**  
преобразование формата даты, времени, единиц измерения и пр.)
- **Преобразование структуры данных (restructuring)**
- **Дедубликация (deduplication)**  
удаление повторных записей

## ETL. Трансформации

- **Фильтрация** (filtering)
  - **Получение производных данных** (derivation)
  - **Агрегирование** (aggregation)
  - **Обобщение/резюме** (summarization)  
сводные данные на разных уровнях, например, страна, регион, город и пр.
  - **Слияние** (merging)
  - **Разделение** (splitting)  
(например, одного столбца на несколько)
- и др.

## ETL. Общая схема



# Поиск информации

# Полнотекстовый поиск

## ➤ Индексирование текстовых документов

- Формирование вектора термов документа (предобработка, токенизация, стемминг и пр.)
- Формирование инвертированного индекса

## ➤ Поиск по текстовому запросу

- Формирование вектора термов запроса (предобработка, токенизация, стемминг и пр.)
- Отбор документов по инвертированному индексу
- Ранжирование отобранных документов по релевантности

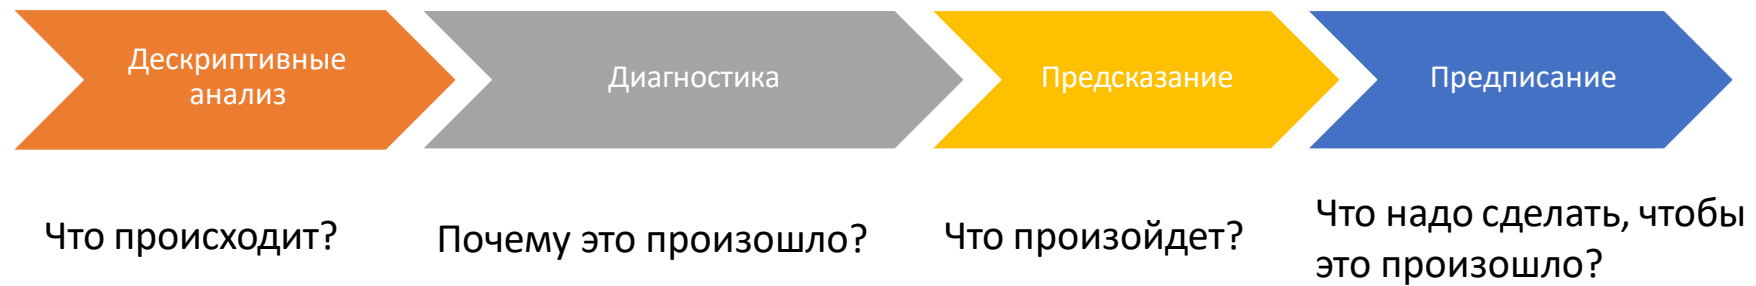
## ➤ Оптимизация





# Анализ данных и машинное обучение

# Анализ данных и машинное обучение



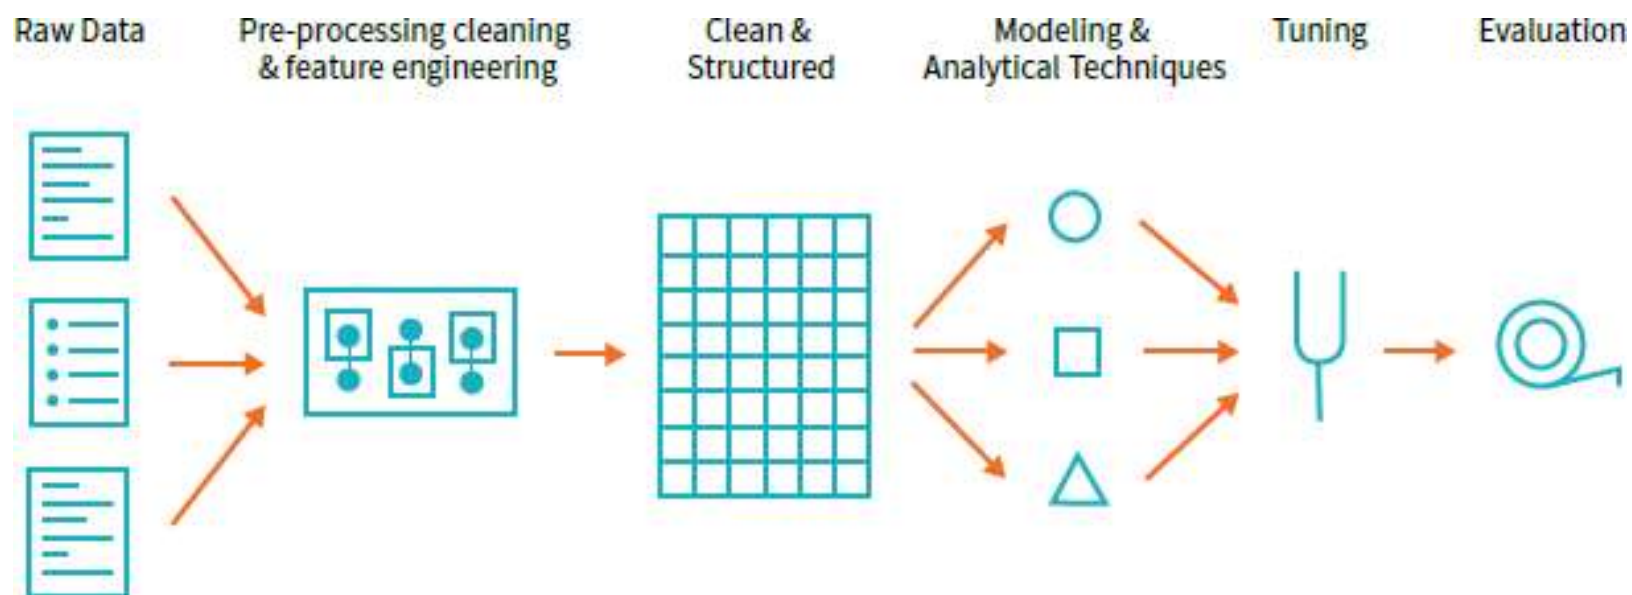
# Анализ данных и машинное обучение

- Дескриптивный анализ
- Предобработка данных (очистка, отбор признаков, преобразование признаков)
- Обучение с учителем (регрессия, классификация)
- Обучение без учителя (кластеризация, уменьшение размерности, выявление аномалий, тематическое моделирование)
- Рекомендательные системы (рекомендации товаров на основе поведения и предпочтений)
- Анализ графов (выявление взаимосвязей различных структур в графе)
- Глубокое обучение

# Решаемые задачи



# Анализ данных и машинное обучение



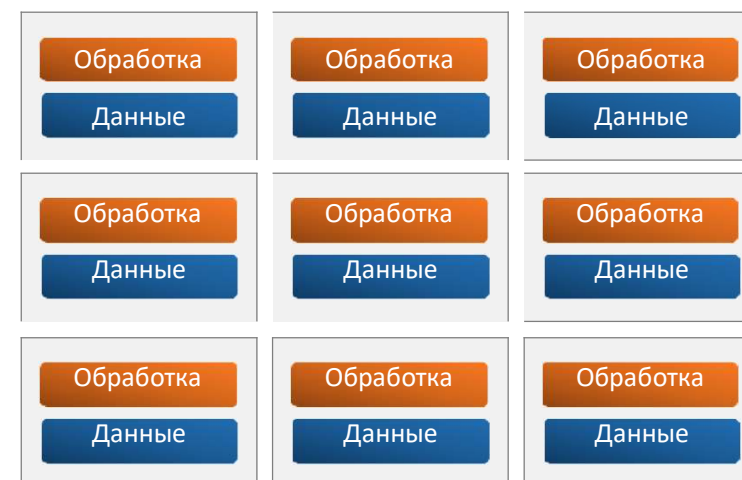
Spark: The Definitive Guide By Bill Chambers & Matei Zaharia (book)

# Архитектура систем обработки больших данных

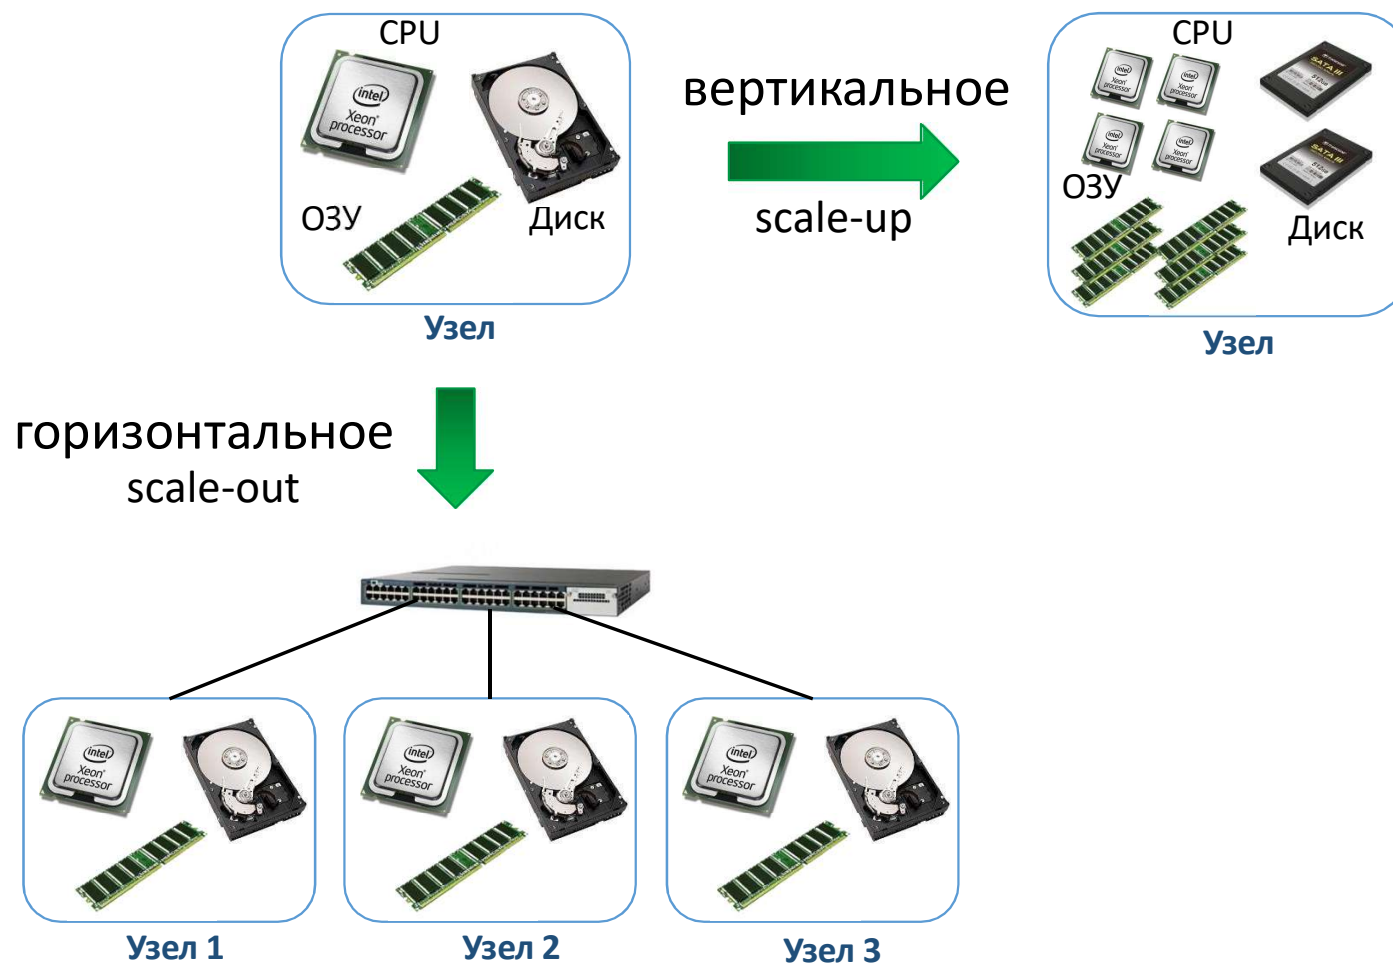
# Вычислительные ресурсы



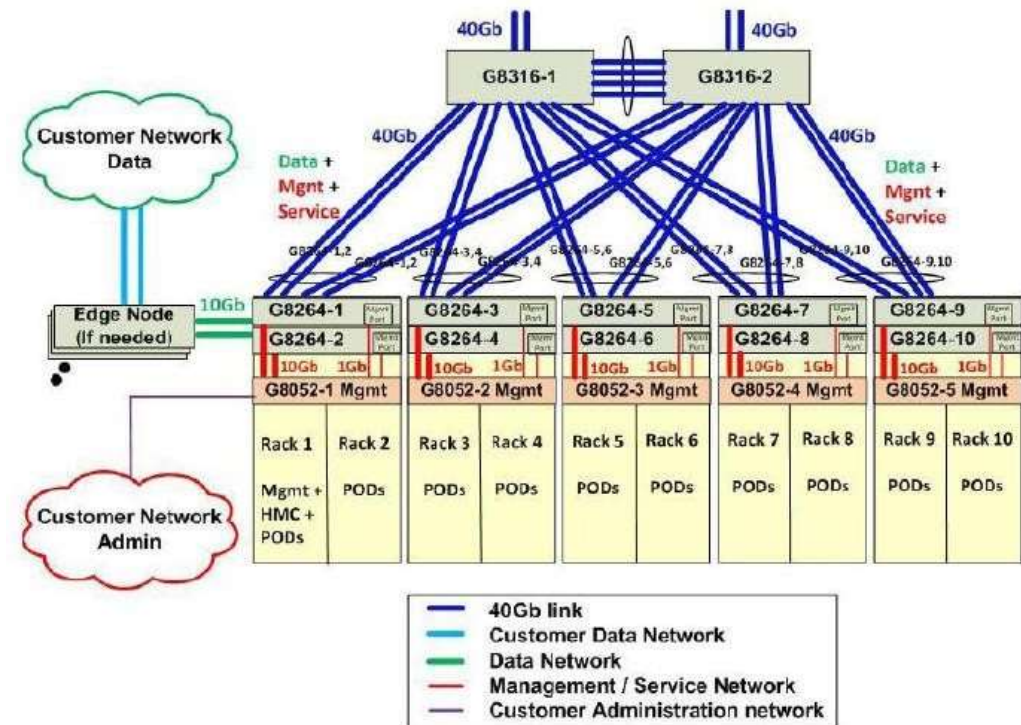
Данные обрабатываются там же, где они хранятся




# Наращивание производительности










# Распределенные приложения

## Что необходимо учитывать

- Сеть не обязательно надежна
- Существуют задержки
- Пропускная способность ограничена
- Сеть может быть небезопасной
- Топология может изменяться
- Может быть несколько администраторов
- Существуют транспортные затраты
- Сеть может быть гетерогенной





## Синхронная

HTTP REST    THRIFT



## Асинхронная

WebSocket



# Координация

## ➤ Выбор мастера (Master election)

Назначение задач worker'ам

## ➤ Обнаружение отказа (Crash detection)

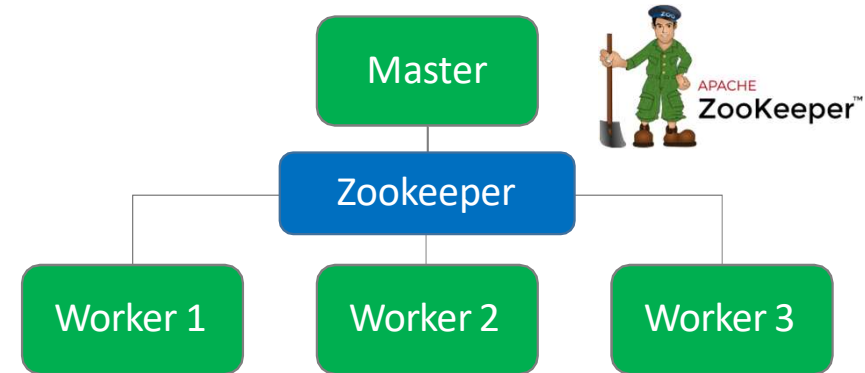
Мастер должен уметь определять, что worker вышел из строя или с ним потеряно соединение

## ➤ Управление группами (Group membership management)

Мастер должен знать, какие worker'ы доступны для выполнения задач


## ➤ Управление метаданными (Metadata management)

Мастер и worker'ы должны хранить задания и статусы выполнения надёжным способом



# Системы обработки и хранения больших данных

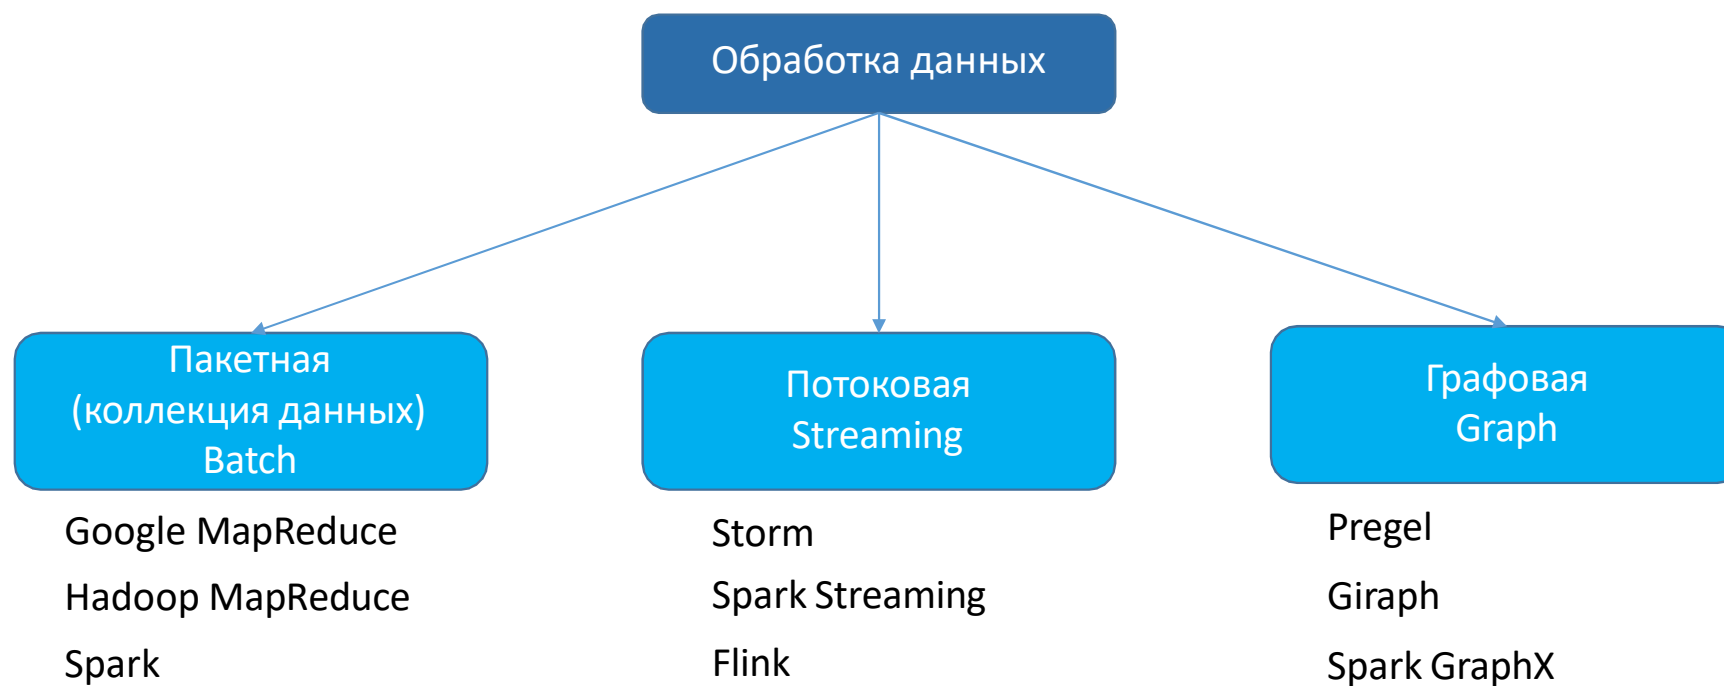
# Вычисления





# Классификация систем

Принципы выполнения вычислений




## Обработка коллекций данных (batch processing)



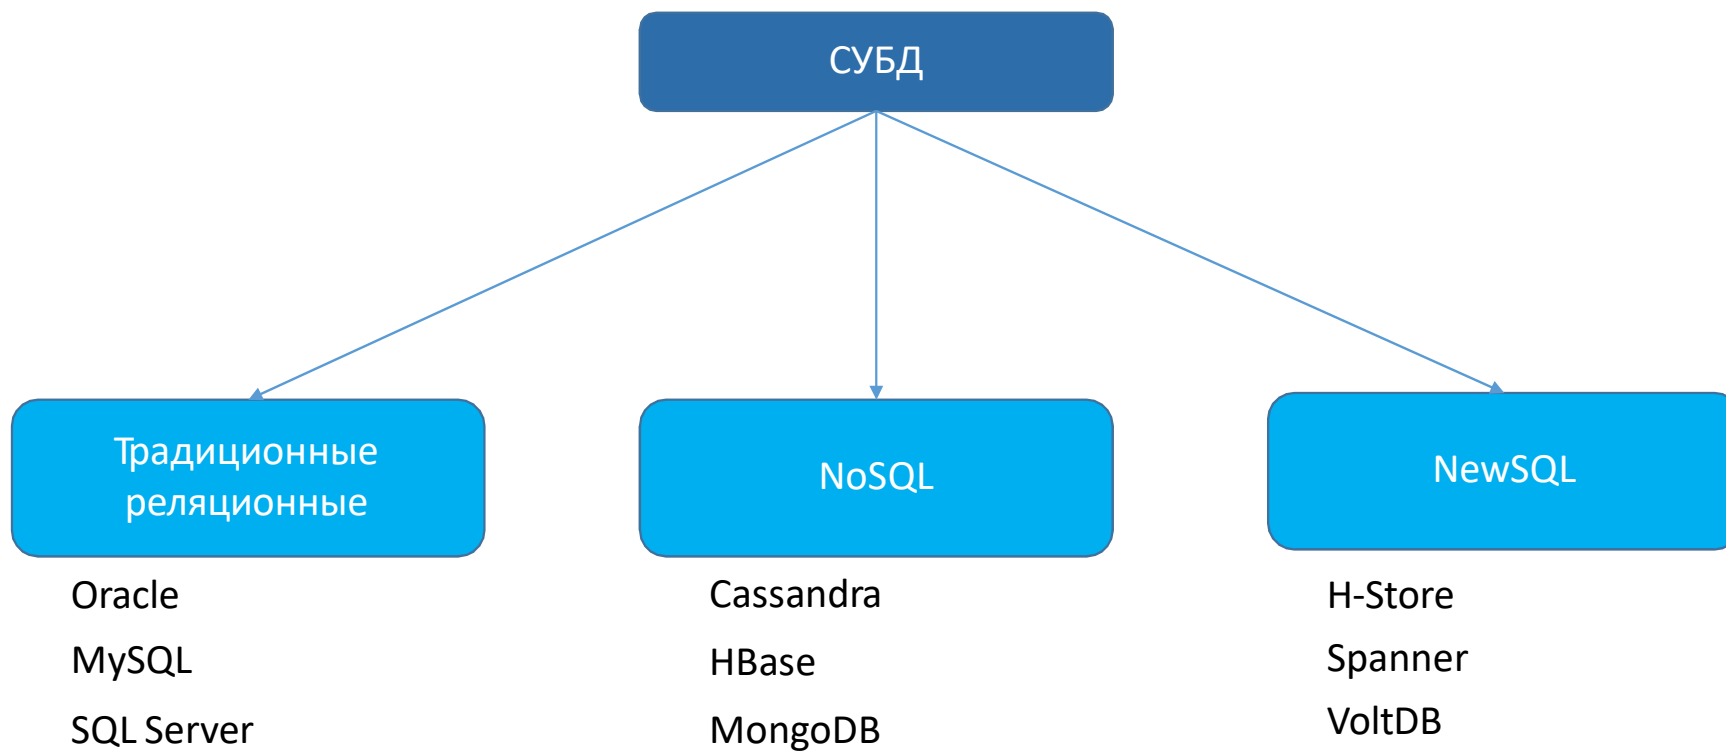
# Обработка потоковых данных (stream processing)



## Обработка графов (graph processing)



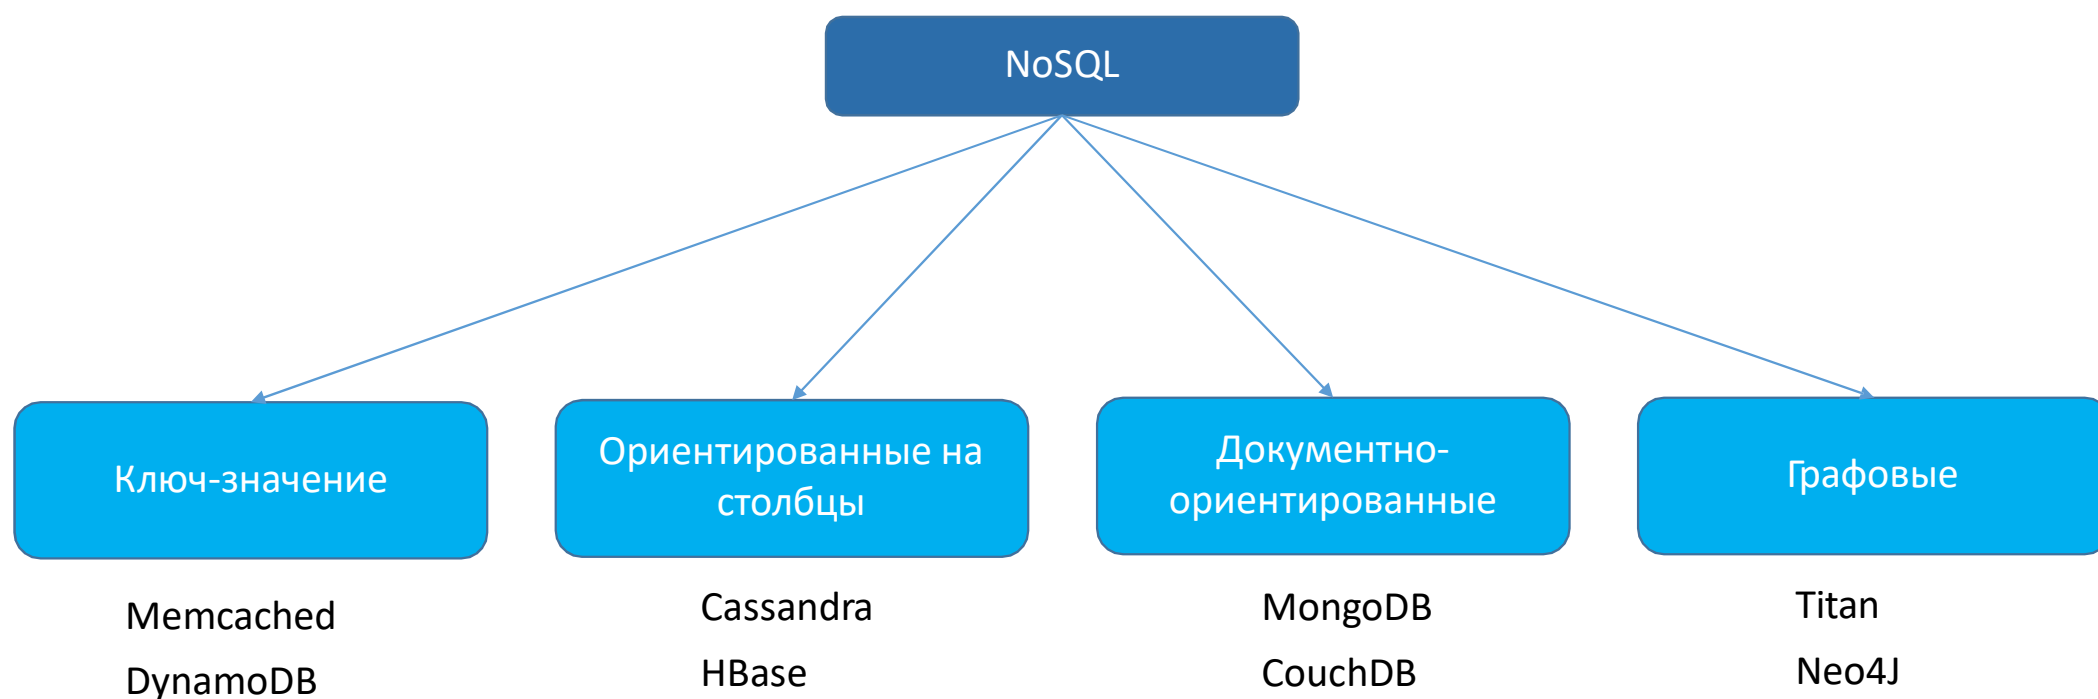
# Классификация NoSQL СУБД



# CAP



# Классификация NoSQL СУБД



# Примеры СУБД

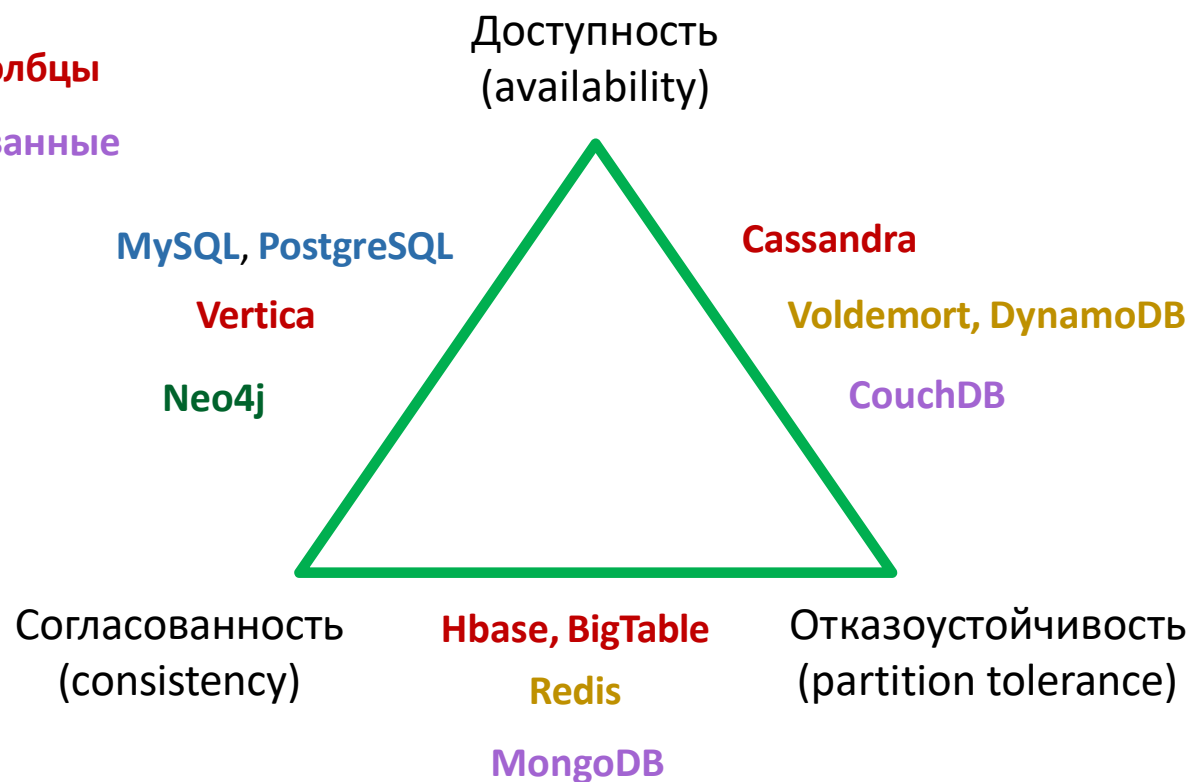
Реляционные

Ключ-значение

Оrientированные на столбцы


Документно-ориентированные

Графовые





# Примеры СУБД



Customer Table

CustomerID	Title	FirstName	LastName	AddressID
1	Mr	Mark	Hanson	500
2	Ms	Lisa	Andrews	501
3	Mr	Walter	Harp	500

Address Table

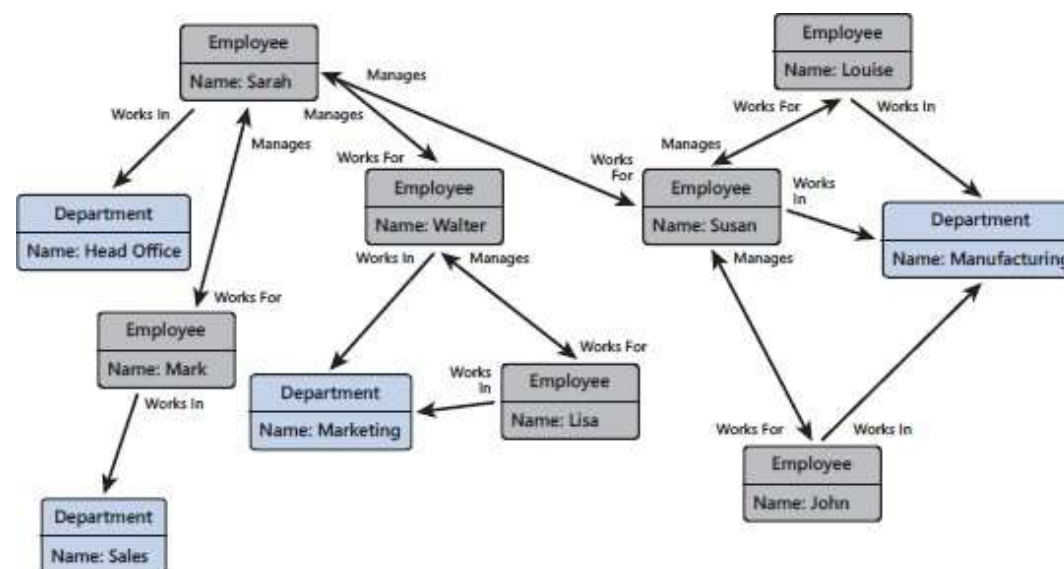
AddressID	StreetAddress	City	State	ZipCode
500	999 500th Ave	Bellevue	WA	12345
501	888 W. Front St	Boise	ID	54321

Key	Value (blob)
AAAAA	110100100100111101001001001
AABAB	000110100111100100011110010
DFA766	01011001100100110011111001011
FABCC4	1111000011001010010110011001

Row Key	Column Families			
CustomerID	CustomerInfo		AddressInfo	
1	CustomerInfo:Title	Mr	AddressInfo:StreetAddress	999 Thames St
	CustomerInfo:FirstName	Mark	AddressInfo:City	Reading
	CustomerInfo:LastName	Hanson	AddressInfo:County	Berkshire
2			AddressInfo:PostCode	RG99 922
	CustomerInfo:Title	Ms	AddressInfo:StreetAddress	888 W. Front St
	CustomerInfo:FirstName	Lisa	AddressInfo:City	Boise
3	CustomerInfo:LastName	Andrews	AddressInfo:State	ID
			AddressInfo:ZipCode	54321
	CustomerInfo:Title	Mr	AddressInfo:StreetAddress	999 500th Ave
	CustomerInfo:FirstName	Walter	AddressInfo:City	Bellevue
	CustomerInfo:LastName	Harp	AddressInfo:State	WA
			AddressInfo:ZipCode	12345

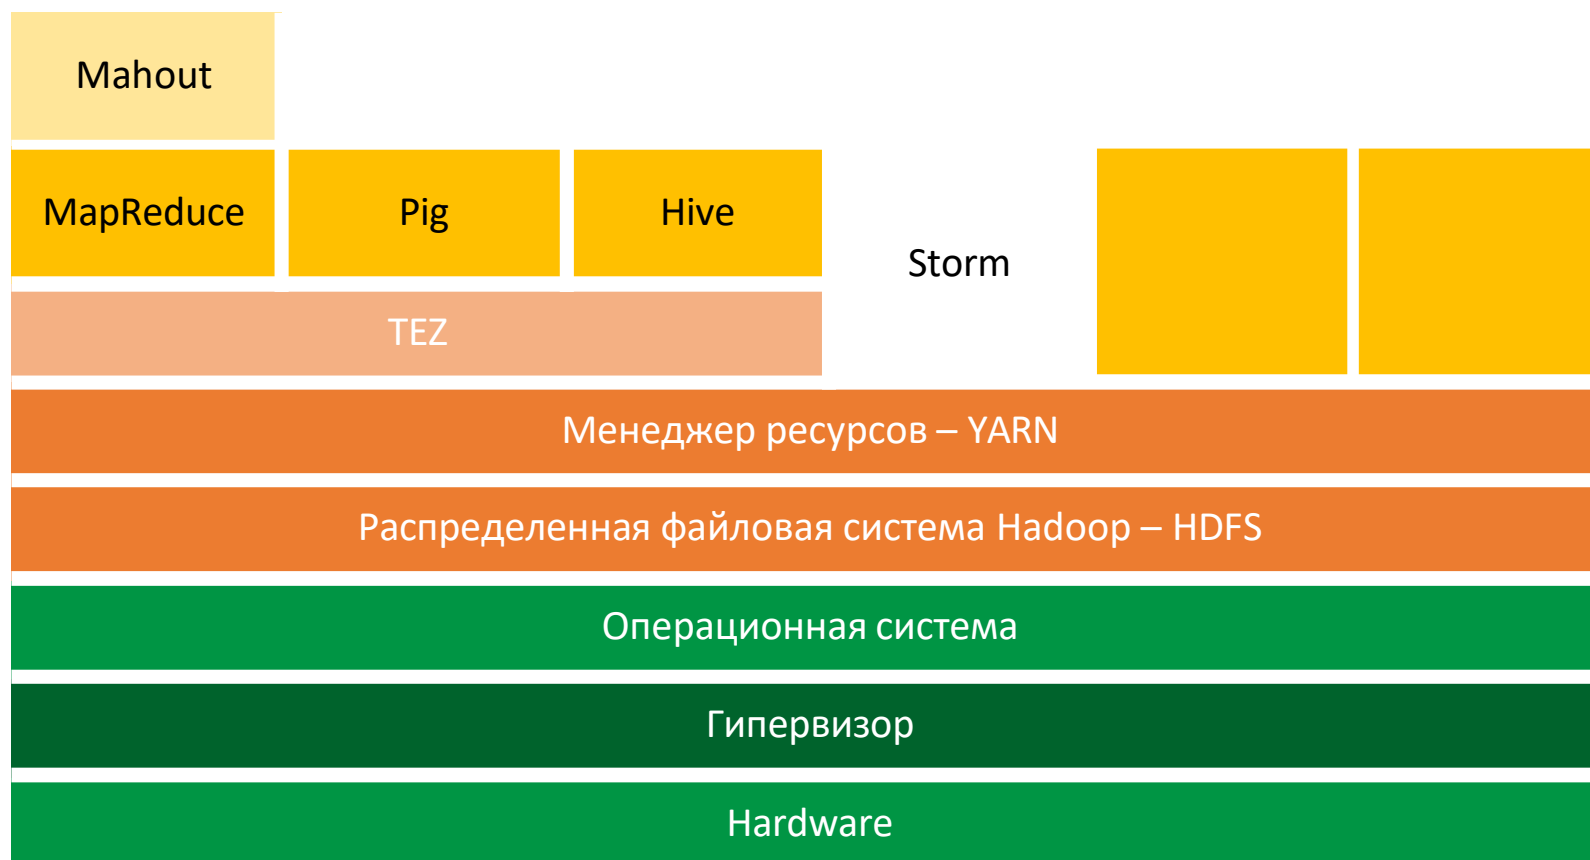
# Примеры СУБД

Row Key	Document
1001	<p>OrderDate: 06/06/2013  OrderItems: ProductID: 2010  Quantity: 2  Cost: 520</p> <p>ProductID: 4365  Quantity: 1  Cost: 18</p> <p>OrderTotal: 1058  Customer ID: 99  ShippingAddress: StreetAddress: 999 500th Ave  City: Bellevue  State: WA  ZipCode: 12345</p>
1002	<p>OrderDate: 07/07/2013  OrderItems: ProductID: 1285  Quantity: 1  Cost: 120</p> <p>OrderTotal: 120  Customer ID: 220  ShippingAddress: StreetAddress: 888 W. Front St  City: Boise  State: ID  ZipCode: 54321</p>

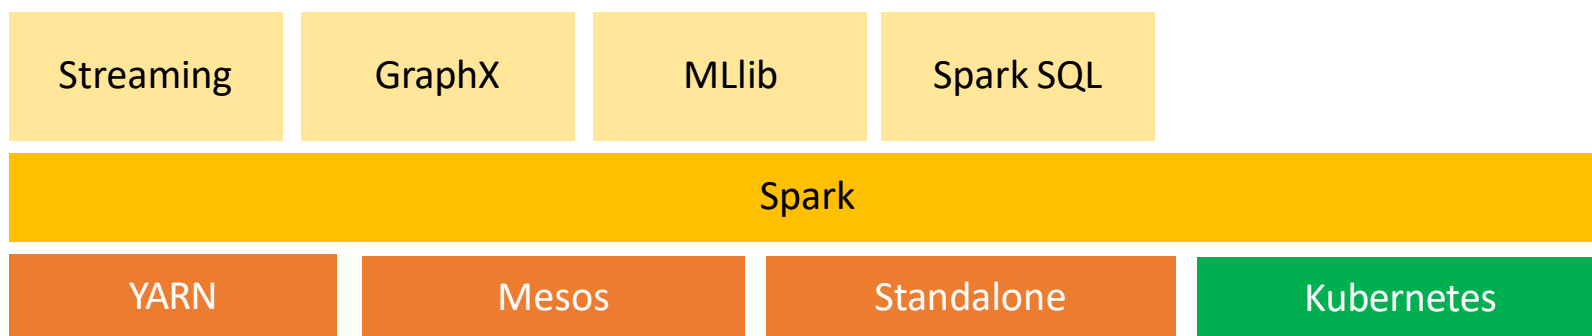


# Стек технологий Hadoop и Spark

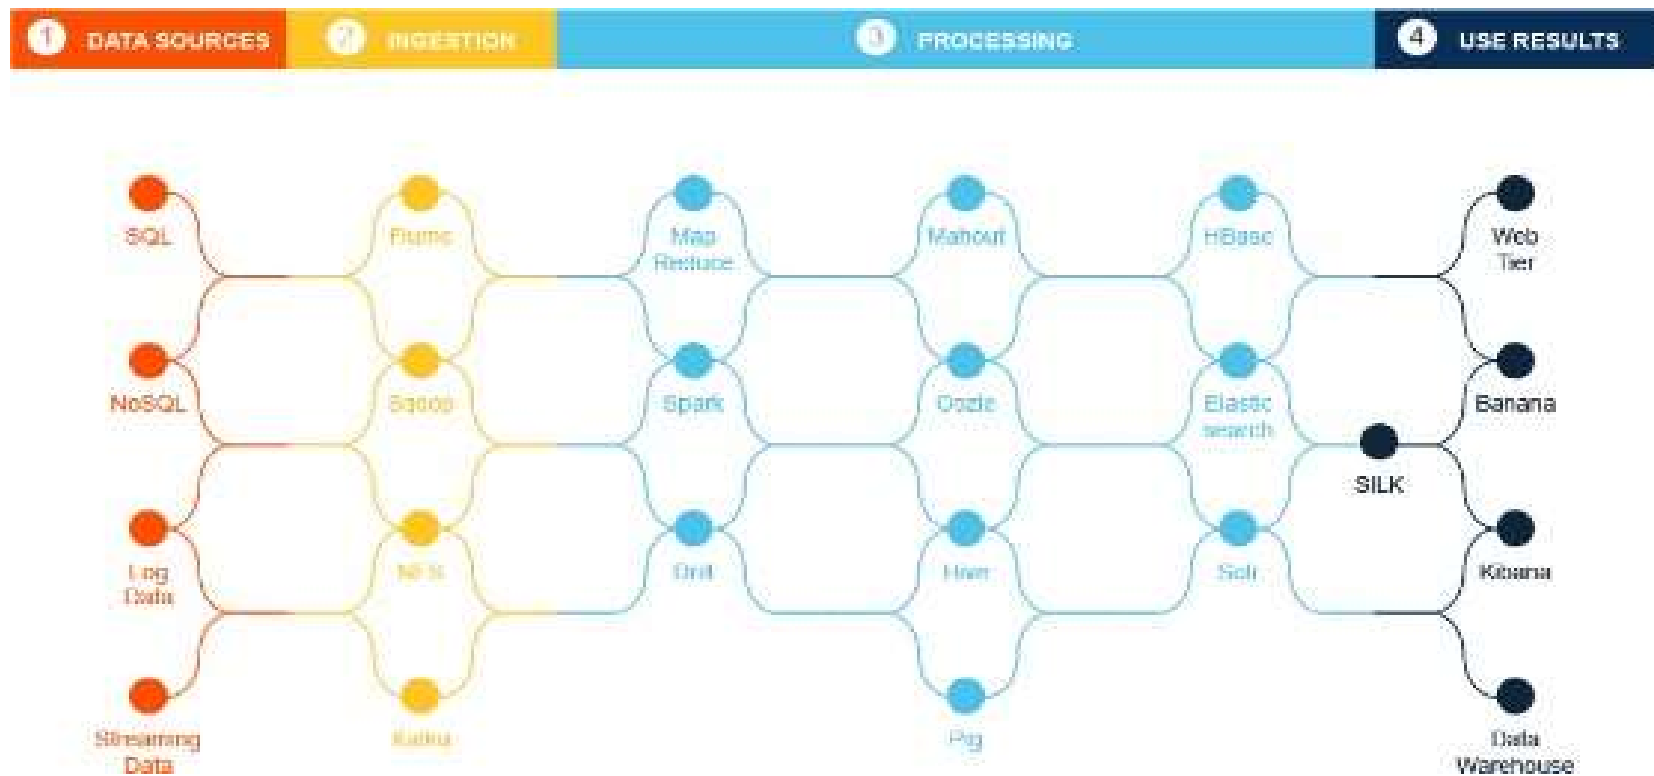
# Стек Hadoop



# Стек Spark

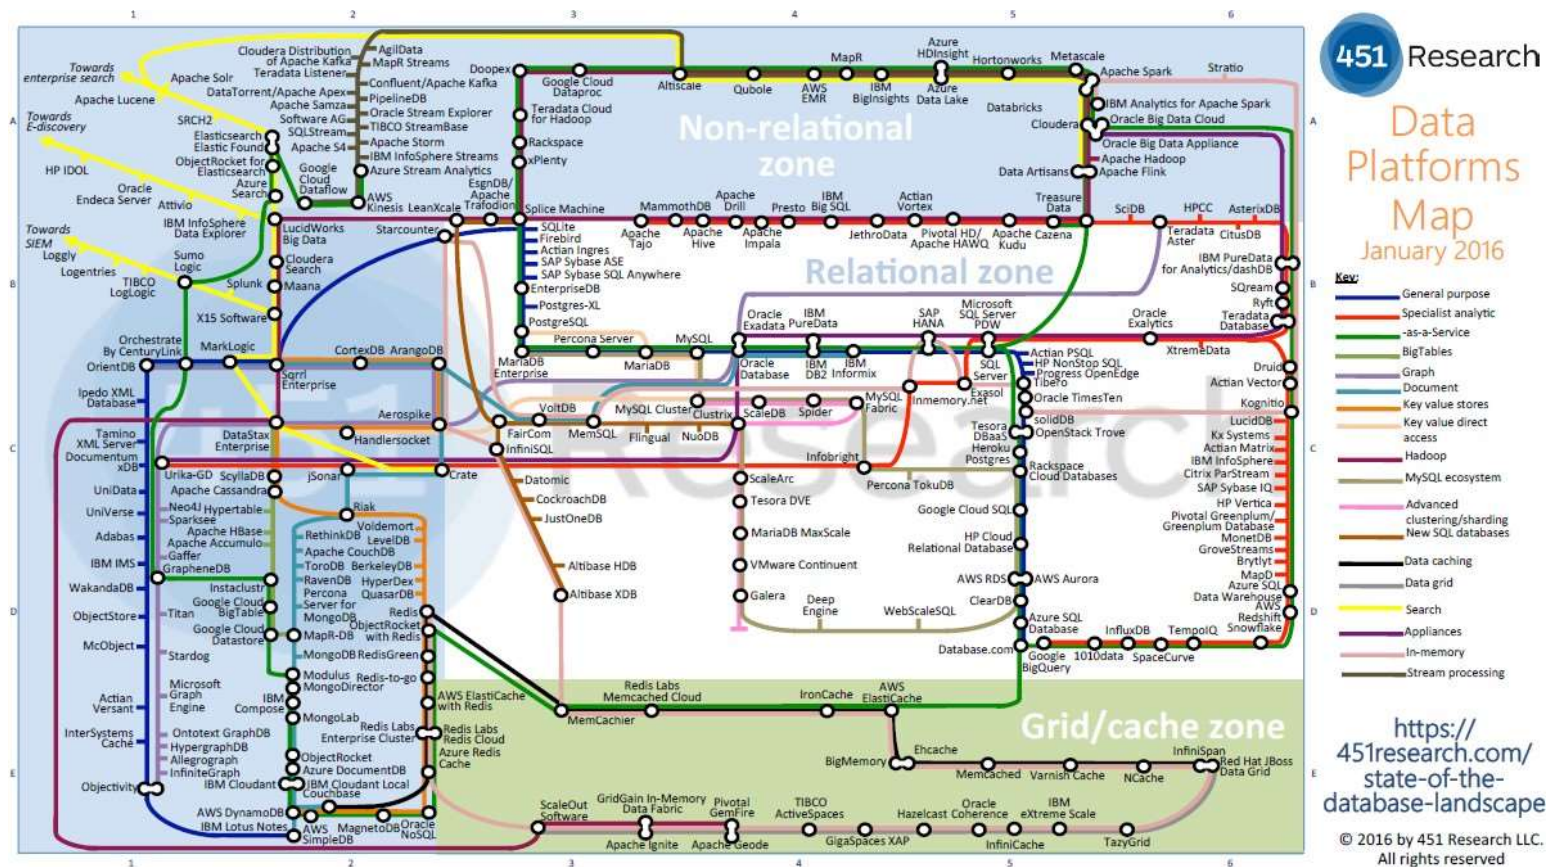


# Стек технологий



MapR

# Карта технологий



# Облачные ресурсы



# Облачные ресурсы

Magic Quadrant for Cloud Infrastructure as a Service



Figure 1. Magic Quadrant for Cloud Infrastructure and Platform Services



# Облачные ресурсы



## Облачные ресурсы

### Инфраструктуры анализа больших данных




Hadoop и Spark  
**Amazon EMR**



Elasticsearch  
**Сервис Amazon Elasticsearch**

### Анализ больших данных в режиме реального времени



**Amazon Kinesis Firehose**



**Amazon Kinesis Streams**



**Amazon Kinesis Analytics**

## Облачные ресурсы

### Хранилища и базы больших данных



Объектное хранилище  
**Amazon S3**



NoSQL  
**Amazon DynamoDB**



HBase в Amazon EMR



Реляционные базы данных  
**Amazon RDS**



Графовые базы данных  
**Amazon DynamoDB для БД Titan**